

Inferencia Estadística (M0.155)

Ejercicio PEC1 Semestre 1 curso 25/26

Ejercicio 1 (5 puntos)

Los efectos secundarios de una medicación vienen identificados por la combinación de tres efectos diferentes A, B y C en cada paciente, pudiendo observar varios de ellos. Se tiene que las probabilidades de cada síntoma es $P(A)=P(B)=p$ y $P(C)=2p$

Además $P(A)=p(B)=p$ y $P(C)=2p$ y por tanto $p(\text{NoA})=P(\text{NoB})=1-p$ y $p(\text{NoC})=1-2p$

1.-Calcular la distribución de probabilidad del número total de efectos de la medicación en un paciente

Se trata de construir la distribución de la variable X donde X es el número total de efectos que puede tomar valores 0,1,2,3. Si asumimos que los cuatro efectos son independientes podemos obtener dichas probabilidades

Además $X=A+B+C$ donde A,B y C son variables Bernoulli (toman valor 0 y 1 con una probabilidad conocida, con lo que X es la suma de tres Bernoulli de parámetros p , p i 2p)

$$P(X = 0) = P(\text{NoA} \cap \text{NoB} \cap \text{NoC}) = (1 - p)(1 - p)(1 - 2p) = (1 - p)^2(1 - 2p) = (1 - 2p + p^2)(1 - 2p) = 1 - 2p + p^2 - 2p + 4p^2 - 2p^3 = \mathbf{1 - 4p + 5p^2 - 2p^3}$$

$$P(X = 1) = P(A \cap \text{NoB} \cap \text{NoC}) + P(\text{NoA} \cap B \cap \text{NoC}) + P(\text{NoA} \cap \text{NoB} \cap C) = p(1 - p)(1 - 2p) + (1 - p)p(1 - 2p) + (1 - p)(1 - p)2p = 2(p(1 - p)(1 - 2p))(1 - p)(1 - p)2p = 2p(1 - p)(1 - 2p + 1 - p) = 2p(1 - p)(2 - 3p) = (2p - 2p^2)(2 - 3p) = 4p - 6p^2 - 4p^2 + 6p^3 = \mathbf{4p - 10p^2 - 6p^3}$$

$$P(X = 2) = P(A \cap B \cap \text{NoC}) + P(A \cap \text{NoB} \cap C) + P(\text{NoA} \cap B \cap C) = pp(1 - 2p) + p(1 - p)2p + (1 - p)p2p = p^2 - 2p^3 + 2p^2 - 2p^3 + 2p^2 - 2p^3 = \mathbf{5p^2 - 6p^3}$$

$$P(X = 3) = P(A \cap B \cap C) = pp2p = \mathbf{2p^3}$$

2.-Calcular la media y la varianza de la distribución del número total de defectos

Para calcular la media o valor esperado y recordando que el valor esperado de una Bernoulli es la probabilidad del éxito y que el valor esperado de una variable suma es la suma de valores esperados

$$E[X] = E[A + B + C] = E[A] + E[B] + E[C] = p + p + 2p = \mathbf{4p}$$

Por otra parte si las variables son independientes la varianza de la suma es la suma de varianzas y varianza de una Bernoulli es la probabilidad de éxito por la probabilidad de fracaso

$$\begin{aligned} \text{Var}[X] &= \text{Var}[A + B + C] = \text{Var}[A] + \text{Var}[B] + \text{Var}[C] \\ &= p(1-p) + p(1-p) + 2p(1-2p) = p - p^2 + p - p^2 + 2p - 4p^2 = 4p - 6p^2 \end{aligned}$$

Para estimar los valores de p se toma una muestra de 200 pacientes encontrando 12 con el efecto A, 8 con B, 18 con el C, pudiendo tener más de un efecto un paciente.

3.-Dibujar la función de verosimilitud para p (puedes usar R)

La función de verosimilitud $L(p)$ es la probabilidad de las observaciones en este caso de observar 12 con efecto A, 8 con efecto B y 18 con C

En general

$$\begin{aligned} L(p) &= p^A(1-p)^{(n-A)}p^B(1-p)^{(n-B)}(2p)^C(1-2p)^{(n-C)} \\ &= 2^C p^{(A+B+C)}(1-p)^{(2n-A-B)}(1-2p)^{(n-C)} \end{aligned}$$

Si sustituimos los valores de A, B y C

$$\begin{aligned} L(p) &= p^{12}(1-p)^{200-12}p^{18}(1-p)^{200-18}2p^{18}(1-2p)^{200-18} = 2^{18}p^{12+8+18}(1-p)^{400-12-8}(1-2p)^{200-18} \\ &= 2^{18}p^{38}(1-p)^{380}(1-2p)^{182} \end{aligned}$$

Así la log-verosimilitud será

$$\ell(p) = C\ln(2) + (A + B + C)\ln(p) + (2n - A - B)\ln(1-p) + (n - C)\ln(1-2p)$$


Si sustituimos los valores de A, B y C

$$\begin{aligned} \ell(p) &= 18\ln(2) + (12 + 8 + 18)\ln(p) + (400 - 12 - 8)\ln(1-p) + (200 - 18)\ln(1-2p) \\ &= 18\ln(2) + 38\ln(p) + 380\ln(1-p) + 182\ln(1-2p) \end{aligned}$$

El valor p tiene que ser inferior a 0.5 ya que $P(C)=2p$ y por definición menor que 1 así


$18\ln(2) + 38\ln(p) + 380\ln(1-p) + 182\ln(1-2p)$ Dibujamos la función en R

```
p <- seq(0.01, 0.49, by=0.001)
loglik <- 18*log(2) + 38*log(p) + 380*log(1-p) + 182*log(1-2*p)
plot(p, loglik, type="l", main="Log-verosimilitud para p")
```



```
Lik<- 18^2 *p^38* (1-p)^380* (1-2*p)^182
```

```
plot(p,Lik, type="l", main="Verosimilitud para p")
```



4.-Encontrad el estimador máximo verosímil $\hat{p}_{EMV}$ Si no puedes obtenerlo analíticamente puedes simularlo a partir de los valores de la función de verosimilitud.

A partir de la función calculada en el apartado anterior el valor máximo se obtiene en R de la siguiente forma y es $\hat{p}_{EMV} = 0.047$

```
p_hat <- p[which.max(loglik)]
p_hat
## [1] 0.047
```

Para calcular el estimador máximo verosímil hemos de calcular la primera derivada de la función y calcular el valor p que sea 0. Para calcular la derivada calculamos la derivada de cada sumando y multiplicamos por el escalar. Como el primero es un número constante su derivada es 0 y la derivada de $\log(p)=1/p$, la derivada de $\log(1-p)=-1/(1-p)$ y la derivada de $\log(1-2p)=-2/(1-2p)$

$$\partial \ell(p) = 18\ln(2) + 38\ln(p) + 380\ln(1-p) + 182\ln(1-2p) = \frac{38}{p} - \frac{380}{1-p} - \frac{364}{1-2p}$$

sumamos la fracciones e igualamos el numerador a 0

$$\begin{aligned} 0 &= 38(1-p)(1-2p) - 380p(1-2p) - 364p(1-p) \\ &= 38(1-3p+2p^2) - 380(p-2p^2) - 364p+364p^2 \\ &= 38-114p+76p^2-380p+760p^2-364p+364p^2 \end{aligned}$$

Hay que resolver la ecuación de segundo grado

$$1200p^2 - 858p + 38 = 0$$

Usamos la fórmula general

$$p = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

Sustituyendo,

$$p = \frac{858 \pm \sqrt{858^2 - 4 \cdot 1200 \cdot 38}}{2 \cdot 1200}$$

Calculamos en R los valores teniendo en cuenta que hay dos posibles soluciones

```
p1<- (858+ sqrt(858^2-4*1200*38))/(2*1200)
p1
## [1] 0.6675638
p2<- (858- sqrt(858^2-4*1200*38))/(2*1200)
p2
## [1] 0.04743616
cat("Como p tiene que ser inferior a 0.5, la estimación de p es", p2)
## Como p tiene que ser inferior a 0.5, la estimación de p es 0.04743616
```

5.-Obtened el estimador, $\hat{p}_{EMM}$, del método de los momentos de p . Tened en cuenta el valor esperado de la distribución del número de efectos.

Según hemos visto en el apartado 2 $E[X]=4p$

El valor de la media muestral es $\hat{X} = (A + B + C)/n = (12 + 8 + 18)/200 = 38/200 = 0.19$

Asi por el metodo de momentos $4\hat{p}_{EMM} = 0.19$

$$\hat{p}_{EMM} = 0.19/4 = 0.0475$$

Los estimadores maximo-versosimil y por momentos son muy parecidos aunque no iguales.

Ejercicio 2 (5 puntos)

En el año 2024 se publicó en la prestigiosa revista JAMA el artículo Effectiveness of Virtual Yoga for Chronic Low Back Pain A Randomized Clinical Trial que podéis encontrar en

<https://jamanetwork.com/journals/jamanetworkopen/fullarticle/2825746>. Las variables principales son la intensidad del dolor, la función relacionada con la espalda y la calidad del sueño medidas a las 6, 12 y 24 semanas del inicio del ensayo. La población se dividió en dos grupos los que empezaron yoga virtual en seguida (yoga now n=71) y los que esperaron 24 semanas en una lista de espera para clases presenciales (yoga later n=69)

Table 2. Primary and Secondary Outcomes

Outcome Measure	Mean change from baseline (95% CI)					
	6 wk	P value	12 wk	P value	24 wk	P value
Pain intensity^a						
Yoga now	-1.4 (-1.99 to -0.89)	NA	-1.8 (-2.3 to -1.2)	NA	-2.4 (-3.0 to -1.9)	NA
Yoga later	-0.1 (-0.6 to 0.4)	NA	-0.3 (-0.8 to 0.2)	NA	-0.1 (-0.6 to 0.5)	NA
Between-group mean difference	-1.3 (-2.1 to -0.6)	<.001	-1.5 (-2.2 to -0.7)	<.001		
Back-related function (RMDQ)^b						
Yoga now	-2.7 (-3.8 to -1.6)	NA	-4.3 (-5.5 to -3.2)	NA	-6.0 (-7.1 to -4.9)	NA
Yoga later	-0.3 (-1.4 to 0.7)	NA	-1.6 (-2.6 to -0.6)	NA	-1.4 (-2.4 to -0.4)	NA
Between-group mean difference	-2.4 (-3.9 to -0.9)	.002	-2.8 (-4.3 to -1.3)	<.001	-4.6 (-6.1 to -3.1)	<.001
Sleep quality^c						
Yoga now	0.3 (0.1 to 0.5)	NA	0.4 (0.2 to 0.7)	NA	0.5 (0.3 to 0.7)	NA
Yoga later	0.1 (-0.1 to 0.3)	NA	0.04 (-0.2 to 0.2)	NA	0.1 (-0.2 to 0.3)	NA
Between-group mean difference	0.2 (-0.1 to 0.5)	.17	0.4 (0.1 to 0.7)	.008	0.4 (0.1 to 0.7)	.005

Abbreviation: NA, not applicable; RMDQ, Roland Morris Disability Questionnaire.

^a Measured using an 11-point numerical rating scale for mean pain intensity in the previous week, with 0 indicating no pain and 10 indicating worst pain possible.

^b Scores range from 0 to 23, with higher scores representing poorer function.

^c Measured using the PROMIS Sleep Disturbance Short Form 8a, item 1. Scores range from 0 to 4, with higher scores reflecting better sleep quality.

Tabla 2.

1.-En la semana 6 del estudio, ¿se ha producido una reducción importante de la intensidad del dolor de espalda en el grupo de yoga later? ¿Cuál ha sido la reducción con un 99% de confianza?

Seún los datos de la tabla la reducción en el grupo de yoga later es -0.1 con un intervalo de confianza al 95% entre -0.6 a 0.4.

Para el calculo de ese intervalo se ha utiliztado la formula $\bar{x} \pm t_{0.975,n-1}ee$ donde en en este caso es n=69 y $t_{\{0.975,69-1\}} = 1.9954689$. Así la mitad de la amplitud es

$$me = t_{0.975,n-1}ee \text{ y por tanto } ee = \frac{me}{t_{0.975,n-1}}$$

$$\text{En nuestro caso } ee = \frac{(0.4 - (-0.6))/2}{1.995469} = 0.2505677$$

Así el intervalo al 99% de la reducción será $\bar{x} \pm t_{0.995,n-1}ee$

En R

```

li_95<- -0.6
ls_95<- 0.4
n=69
xm<--0.1
ee<- ((ls_95-li_95)/2)/qt(.975,n-1)
ee

## [1] 0.2505677

li_99<- xm -qt(.995,n-1)*ee
ls_99<- xm +qt(.995,n-1)*ee

cat ("El intervalo de confianza al 99% de la reducción del yoga later a l
as 6 semanas es " ,li_99,";",ls_99)

## El intervalo de confianza al 99% de la reducción del yoga later a las
6 semanas es -0.7640247 ; 0.5640247

```

Según los resultados observados no hay evidencia de que a las seis semanas se observe una reducción ya que el 0 está incluido en el intervalo de confianza al 99%

2.-En la semana 12 ¿existe una diferencia importante entre la reducción del grupo yoga now y yoga later? ¿Cuál ha sido esta diferencia con un 95% de confianza?

Según los datos del artículo la diferencia y su intervalo de confianza al 95% entre las dos reducciones es -1.5 (-2.2 to -0.7). En este caso el valor 0 no está incluido en el intervalo de confianza y podemos indicar con un 95% de confianza que existe una diferencia de reducción entre yoga later y now

3.- El intervalo de confianza que habéis utilizado para responder a la cuestión anterior, ¿puede ser siempre utilizado o requiere algunos requisitos para su construcción? En este último caso, especificad cuáles son estos requisitos para su cálculo .

En el caso de diferencia de medias se requieren algunos requisitos para su cálculo

- Que los dos grupos sean independientes
- Que la variable siga una distribución normal o que el tamaño de cada grupo sea grande para aplicar el Teorema Central del límite
- Que las varianzas sean iguales (Si son diferentes la fórmula del error estándar es más compleja)

4.- En la semana 24 como interpretas los resultados relativos a la tabla en el caso de yoga now y yoga later, y calcula el intervalo de confianza al 99% que falta de la diferencia. Indica paso a paso cómo has calculado el intervalo de confianza e interpreta los resultados.

En la semana 24 se observa que hay una reducción en el caso del yoga now ya que el intervalo no incluye al 0, però no hay evidencia para indicar existe la reducción en el caso del yoga later ya que el 0 está incluido en el intervalo.

Para la segunda parte del cálculo del intervalo de confianza de la diferencia hemos de calcular en primer lugar la diferencia

de la media de reducción del yoga now - la media de reducción del yoga later $\overline{difx} = \bar{x}_{now} - \bar{x}_{later} = -2.4 - (-0.1) = -2.3$

para el calculo del intervalo de confianza al 99% de la diferencia de medias

$$\overline{difx} \pm t_{0.995, n_1+n_2-2} \sqrt{ee_{low}^2 + ee_{later}^2}$$

Para obtener el error estándar de cada grupo usamos las formulas del primer ejercicio

$ee = \frac{ls-li}{t_{0.975, n-1}}$ y multiplicando por la raiz cuadrada del tamaño muestral obtenemos la desviación típica

$$sd = ee\sqrt{n}$$

En R

```
li1_95<- -3.0
ls1_95<- -1.9
n1=71
xm1<- -2.4
ee1<- ((ls1_95-li1_95)/2)/qt(.975,n1-1)
ee1

## [1] 0.275767

sd1<- ee1*sqrt(n1)
sd1

## [1] 2.323654

li2_95<- -0.6
ls2_95<- 0.5
n2=69
xm2<- -0.1
ee2<- ((ls2_95-li2_95)/2)/qt(.975,n2-1)
ee2

## [1] 0.2756244

sd2<- ee2*sqrt(n2)
sd2

## [1] 2.289509
```



```
difx<-xm1-xm2
difx

## [1] -2.3

ee_dif<- sqrt( ee1^2+ee2^2)
ee_dif2<- ( sqrt(((n1-1)*sd1^2 + (n2-1)*sd2^2)/ (n1+n2-2)))*(sqrt(1/n1+
1/n2))

li_99<- difx -qt(.995,n1+n2-2)*ee_dif
ls_99<- difx +qt(.995,n1+n2-2)*ee_dif

cat ("El intervalo de confianza al 99% de la reducción del yoga later a l
as 6 semanas es " ,li_99,";",ls_99)

## El intervalo de confianza al 99% de la reducción del yoga later a las
6 semanas es -3.31837 ; -1.28163
```

El valor 0 no esta incluido en el intervalo de confianza al 99% indicando que podemos asumir que las reducciones son diferentes en los dos grupos

5. Supongamos que se quisiera diseñar el estudio para que el intervalo de confianza para la reducción de la intensidad de dolor de 2 puntos en el grupo de Yoga now tuviera una amplitud máxima de 0.8 puntos con un nivel de confianza del 95%. Calculad el tamaño muestral que sería necesario en cada grupo para alcanzar esta precisión, asumiendo que la desviación estándar que se deduce de la tabla del artículo es representativa. Repetid el cálculo para el intervalo de confianza para la variable de la función relacionada con la espalda (RMDQ). Viendo estos dos resultados, que comentaríais sobre los estudios que realizan un cálculo de tamaño muestral basándose tan sólo en una variable.

Segun el apartado anterior la desviación típica es $sd = 2.3236543$, la reducción a observar es 2 y la amplitud del intervalo es 0.8 , es decir la precisión es $d=0.4$

El valor $\alpha=0.5$

Y substituyendo en la formula siguiente obtendremos el valor de N.

$$n = \frac{z_{1-\alpha/2}^2 sd^2}{d^2} = \frac{z_{1-.05/2}^2 2.289509^2}{0.4^2}$$

En R

```
sigma<-2.289509
d<-0.4
q<-qnorm(.975)

n<-(q*sigma)^2 /d^2

cat(" El tamaño muestral para Pain Intensity es ", n,"\n")
```

```
## El tamaño muestral para Pain Intensity es 125.8522
library(samplingbook)
## Loading required package: pps
## Loading required package: sampling
## Loading required package: survey
## Loading required package: grid
## Loading required package: Matrix
## Loading required package: survival
##
## Attaching package: 'survival'
## The following objects are masked from 'package:sampling':
##
##   cluster, strata
##
## Attaching package: 'survey'
## The following object is masked from 'package:graphics':
##
##   dotchart
sample.size.mean(d,sigma,level=0.95)
##
## sample.size.mean object: Sample size for mean estimate
## Without finite population correction: N=Inf, precision e=0.4 and standard deviation S=2.2895
##
## Sample size needed: 126
```

Para la variable RMDQ hemos de calcular la desviación típica como en apartados anteriores donde la reducción es -6.0 con un intervalo de confianza de -7.1 y -4.9

```
li1_95<- -7.1
ls1_95<- -4.9
n1=71
xm1<- -6.0
ee1<- ((ls1_95-li1_95)/2)/qt(.975,n1-1)
ee1
## [1] 0.5515341
sd1<- ee1*sqrt(n1)
sd1
```

```
## [1] 4.647309

sigma<-sd1
d<-0.4
q<-qnorm(.975)

n<-(q*sigma)^2 /d^2

cat(" El tamaño muestral para RMDQ es ", n,"\n")

## El tamaño muestral para RMDQ es 518.5364

library(samplingbook)
sample.size.mean(d,sigma,level=0.95)

##
## sample.size.mean object: Sample size for mean estimate
## Without finite population correction: N=Inf, precision e=0.4 and stand
ard deviation S=4.6473
##
## Sample size needed: 519
```

Al utilizar la misma amplitud de intervalo de confianza el tamaño muestral cambia siendo más grande en el caso de RMDQ en el que la desviación típica es mayor. Por tanto a la hora de fijar el tamaño muestral de un estudio hay que fijarse en todas las variables principales de estudio y elegir el mayor para garantizar la precisión de las estimaciones.